Sbircea, Stéphanie, n° 22304694,
Pesce Cassandre, n° 22413995

L2 MIASHS
Sciences des données
Enseignante : Nefissa Khiari
Novembre 2025

Classification non supervisée pour l'analyse de recettes de cuisine et supervisée pour l’analyse de photos de différents chats

Résumé du rapport

Dans ce projet, on a exploré deux facettes complémentaires de la science des données à l'aide du logiciel Orange Data Mining : l'analyse textuelle non supervisée et la classification d'images supervisée.

Pour la première partie, on a travaillé sur l'analyse de textes en utilisant un corpus de recettes de cuisine provenant du site Marmiton. L'objectif était de déterminer si la machine pouvait, de manière autonome et sans étiquettes préalables, distinguer les plats salés des préparations sucrées uniquement en analysant le vocabulaire employé. Les résultats ont montré que l'algorithme parvenait à regrouper les recettes de façon logique, isolant les desserts des plats principaux.

Pour la seconde partie, on a adopté une démarche plus personnelle en construisant notre propre base de données à partir de photos des cinq chats de Cassandre: Cotton, Fluffy, Paillette, Pysou et Susu. L'enjeu était d'entraîner Orange à reconnaître l'identité de chaque animal. Après avoir constitué un jeu d'apprentissage et un jeu de test, on a comparé plusieurs modèles de classification. Cette étude nous a permis de mettre au point un système performant, capable d'identifier correctement les animaux de compagnie sur des photos qu'il n'avait jamais vues auparavant.

Ce rapport détaille l'ensemble de notre démarche, depuis la collecte manuelle de nos données jusqu'à l'interprétation critique des résultats obtenus.

Table des matières

Résumé du rapport **1**
Table des matières **2**
Table des figures **3**

1 - Apprentissage non supervisé **5**
1.1 - Jeu de données 5
1.2 - Chaîne de traitement 5
1.3 - Interprétation 7
A. Analyse du dendrogramme obtenu à partir de la distance cosinus 8
B. Distance euclidienne normalisée 9
C. Conclusion de l'analyse non supervisée 10

2 - Apprentissage supervisé **11**
2.1 - Jeu de données 11
2.2 - Chaîne de traitement 12
A. Démarche de prétraitement 13
B. Outils de classification et évaluation 13
2.3 - Interprétation 14
A. Description des résultats d'entraînement et comparaison des modèles 14
B. Interprétation des échecs et des limites 15
C. Analyse de la prédiction sur le jeu de test 16
D. Conclusion de l'Analyse Supervisée 17

Sources **18**

Table des figures

Figure 1 - Capture d'écran du document csv : début des recettes visibles. 4

Figure 2 - Capture d'écran du document orange : chaîne de traitement. 4

Figure 3 - Capture d'écran du document orange - Corpus Viewer : visualisation des recettes. 5

Figure 4 - Capture d'écran du document StopWords : mots retirés de l'analyse Orange. 5

Figure 5 - Capture d'écran du document orange - Word Cloud : mots les plus fréquents (avec stopWords). 6

Figure 6 - Capture d'écran du document orange - Word Cloud : mots les plus fréquents (sans stopWords). 6

Figure 7 - Capture d'écran du document orange - Hierarchical Clustering : distance cosinus. 6

Figure 8 - Capture d'écran du document orange - Hierarchical Clustering : distance euclidienne normalisée. 6

Figure 9 - Capture d'écran du document orange - Hierarchical Clustering : sous-clusters du cluster sucré (distance cosinus). 7

Figure 10 - Capture d'écran du document orange - Hierarchical Clustering : sous-clusters du cluster salé (distance cosinus). 8

Figure 11 - Photo prise d'Image Viewer sur Orange : On y observe les 50 photos classées dans les 5 catégories. 10

Figure 12 - Capture d'écran prise du Workflow d'Orange : On y observe la chaîne de traitement des données supervisées. 11

Figure 13 - Capture d'écran prise de data table connectée directement à l'importation de photos classe 12

Figure 14 - Capture d'écran prise de data table connecte après l'Embedding des photos 12

Tableau 1 - Capture d'écran prise de Test and Score sur la moyenne de toutes les classes : On observe les résultats obtenus via le widget sur le jeu d'entraînement (validation croisée à 10 folds) 13

Figure 15 - Capture d'écran prise d'Image Viewer après confusion Matrix de régression Logistique: On observe que Cotton (Le chat blanc) est classe comme Fuffy (Le chat roux) et vise et versa. 14

Figure 16 - Capture d'écran prise d'Image Viewer après prédictions de Régression Logistique: On observe que Susu (chat noir) est classe comme Paillette (une chatte de pelage blanc-gris et brun). 15

1 - Apprentissage non supervisé

1.1 - Jeu de données

Le jeu de données utilisé dans ce travail est composé de trente recettes récupérées sur le site Marmiton. On a choisi des recettes variées, avec environ la moitié sucrées et l'autre moitié salées, afin de voir comment l'outil Orange arrive à les regrouper.

Chaque recette a été copiée dans un fichier CSV, organisé en trois colonnes :

- Titre de la recette
- Ingrédients
- Préparation

	A	B	C
1	**Titre**	**Ingrédients**	**Préparation**
2	Quiche lorraine maison	200 g de pâte brisée, 200 g de lardons, 30 g de beur	Préchauffer le four à 180°C (thermostat 6). Étaler la pâte dans un mo
3	Ratatouille	350 g d'aubergine, 350 g de courgette, 350 g de poiv	Coupez les tomates pelées en quartiers, les aubergines et les courge
4	Blanquette de veau : recette traditic	2 carottes, 1 oignon jaune, 1 petit pot de crème fraîch	Faire revenir la viande dans un peu de beurre doux jusqu'à ce que les
5	Boeuf bourguignon rapide	100 g de lardons, 50 g de beurre ou 3 cuillères à sou	Hacher les oignons. Peler l'ail. Dans une cocotte minute, faire roussir
6	Lasagnes à la bolognaise	1 paquet de lasagnes, 3 oignons jaunes, 125 g de be	Faire revenir gousses hachées d'ail et les oignons émincés dans un p
7	Couscous poulet et merguez facile	12 merguez, huile d'olive, 1 cuillère à café de harissa	Lavez et épluchez les carottes, les navets et les tomates et les coupe
8	Hachis parmentier	300 g de purée, 2 oignons, 2 tomates fraîches ou pel	Hacher l'oignon et l'ail. Les faire revenir dans le beurre jusqu'à ce qu'i
9	Pizza maison	1 sachet de levure à pain, ½ cuillère à café de bicarb	Dans un saladier, placez les 300 g de farine, puis la levure, puis le bic
10	Tartiflette : la vraie recette	200 g d'oignons émincés, 1 reblochon bien fait (lorsq	Eplucher les pommes de terre, les couper en dés, bien les rincer et le
11	Poivrons farcis à la merguez (facile	4 poivrons, 10 merguez, 2 tomates, 1 oignon	Vider les merguez et les écraser. Les mélanger aux tomates coupées
12	Velouté de potiron et carottes	500 g de carottes, 1 oignon, 1 cuillère à soupe d'huile	Éplucher et couper en dés le potiron, les pommes de terre, les carotte
13	Salade de pâtes au pesto	1 pesto toute prête, tomates cerise, 1 kg de tortils ou	Faire cuire les pâtes 'al dente' dans un faitout avec une bonne quantit
14	Poulet au curry lait de coco et noix	1 cuillère à café de curry, 1 cuillère à soupe de maïze	Concasser les noix de cajou (j'utilise le culot d'un verre dans une assi
15	Gratin dauphinois, recette originale	sel, poivre, 1 kg de pommes de terre belle de Fonten	Préchauffer le four à 150°C (thermostat 5). Eplucher et couper les por

Figure 1 - Capture d'écran du document csv : début des recettes visibles.

Ce sont donc des données textuelles, chaque ligne du CSV correspond à une recette, donc à un individu.

La création du jeu de données a été réalisée manuellement. On a cherché les recettes directement sur le site Marmiton, puis on a copié le titre, la liste des ingrédients et le texte de préparation puis on les a mises dans un tableau au format CSV.

1.2 - Chaîne de traitement

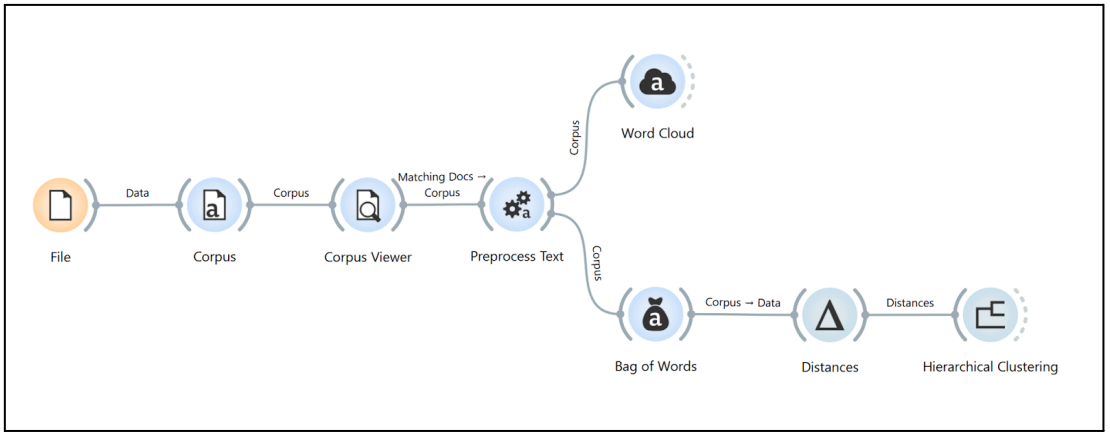


Figure 2 - Capture d'écran du document orange : chaîne de traitement.

La chaîne de traitement mise en place dans Orange suit l'ordre suivant:

1. File : importation du fichier CSV dans Orange.
2. Corpus : transformation du CSV en un corpus textuel exploitable.
3. Corpus Viewer : visualisation du contenu du corpus pour vérifier qu'il n'y a pas d'erreurs de mise en forme.

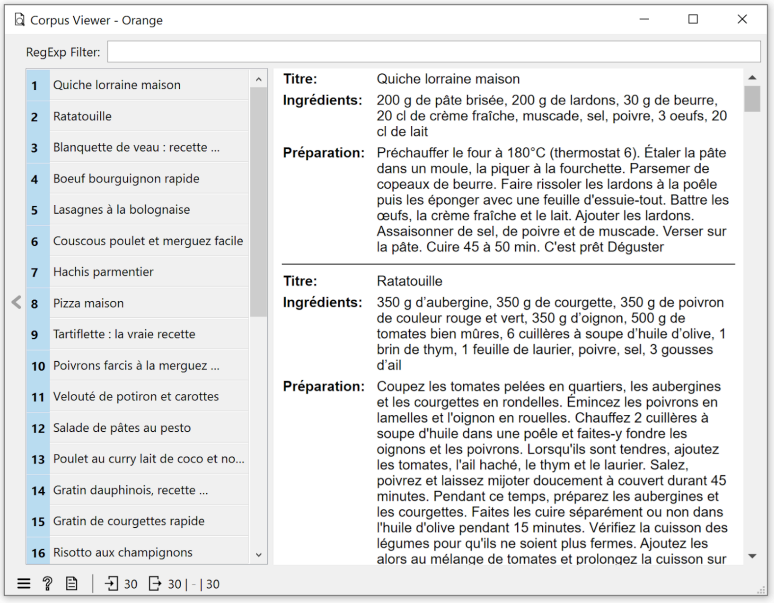


Figure 3 - Capture d'écran du document orange - Corpus Viewer : visualisation des recettes.

4. Preprocess Text : étape de prétraitement pour obtenir des textes propres et comparables:
    - suppression des nombres, liens, ponctuations inutiles
    - conversion en minuscules
    - utilisation d'un fichier de stopwords pour retirer les mots sans intérêt

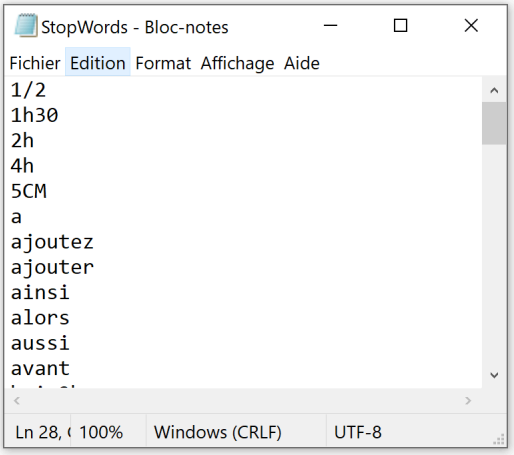


Figure 4 - Capture d'écran du document StopWords : mots retirés de l'analyse Orange.

5. Bag of Words : transforme chaque texte en une liste de mots. Chaque recette devient alors un ensemble de fréquences de mots, ce qui permet ensuite de mesurer les similarités entre recettes.

5.bis. Word Cloud : visualisation des mots les plus fréquents pour repérer rapidement les mots trop courants ou inutiles, afin de les ajouter si besoin à la liste des stopwords.

Avec stopWords

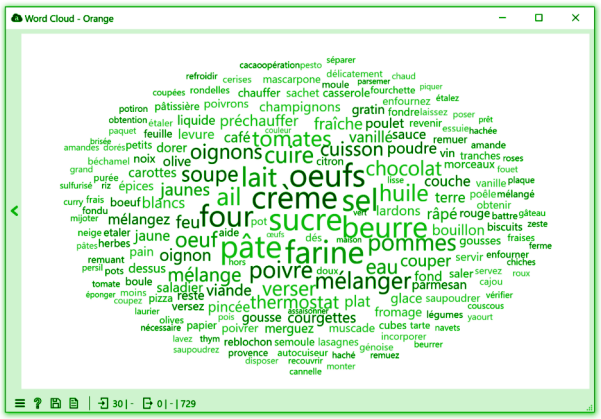


Figure 5 - Capture d'écran du document orange - Word Cloud : mots les plus fréquents (avec stopWords).

Sans stopWords

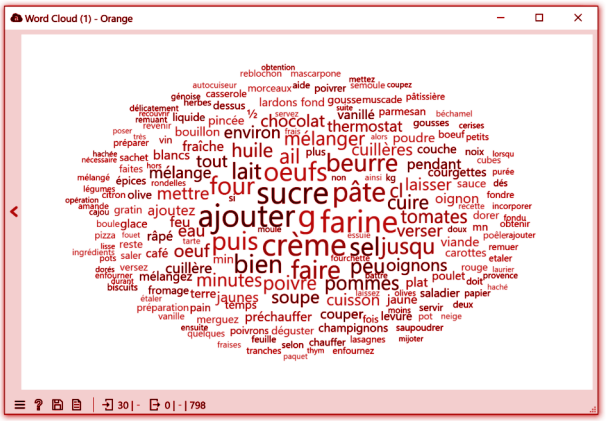


Figure 6 - Capture d'écran du document orange - Word Cloud : mots les plus fréquents (sans stopWords).

6. Distance : calcul des distances entre les recettes (mesure la similarité entre les textes). Ici la distance cosinus semble la plus adaptée.

7. Hierarchical Clustering : création d'un dendrogramme qui montre la manière dont les recettes sont regroupées par Orange selon les distances calculées.

1.3 - Interprétation

L'analyse a été réalisée principalement avec deux distances : la distance cosinus et la distance euclidienne normalisée. Les autres distances testées donnent des résultats moins cohérents, donc on ne les a pas retenues.

Les dendrogrammes obtenus sont les suivants :

distance cosinus

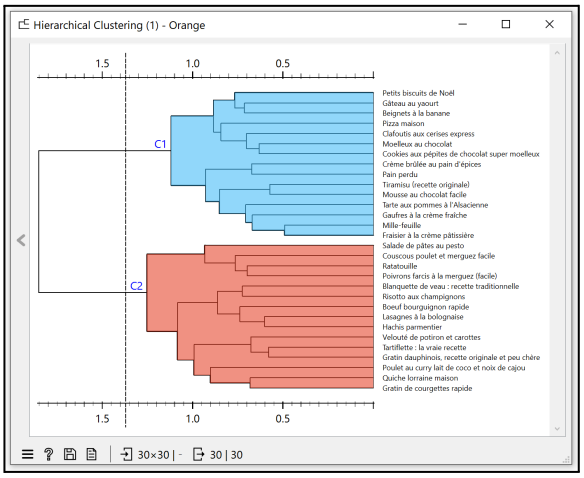


Figure 7 - Capture d'écran du document orange - Hierarchical Clustering : distance cosinus.

distance euclidienne normalisée

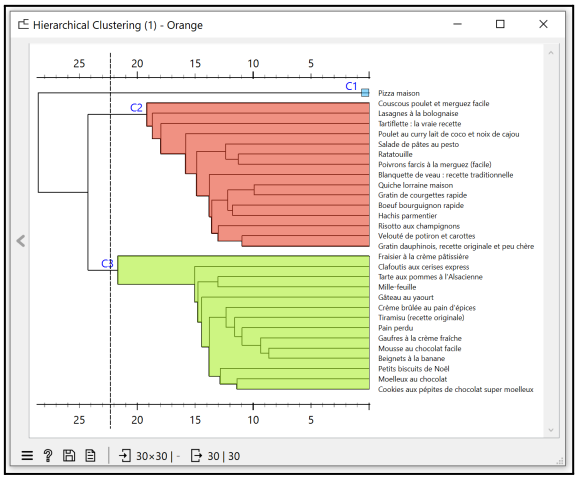


Figure 8 - Capture d'écran du document orange - Hierarchical Clustering : distance euclidienne normalisée.

Dans les deux cas, un point revient systématiquement : la recette de la pizza maison est la seule mal classée. Le reste des recettes se répartit en deux grands ensembles : un cluster regroupant les recettes salées et un autre regroupant les recettes sucrées.

La distance cosinus met en évidence davantage de sous-clusters à l'intérieur de ces deux groupes, c'est donc la plus intéressante à interpréter.

A. Analyse du dendrogramme obtenu à partir de la distance cosinus

- **Cluster 1 (C1) : recettes sucrées + pizza maison**

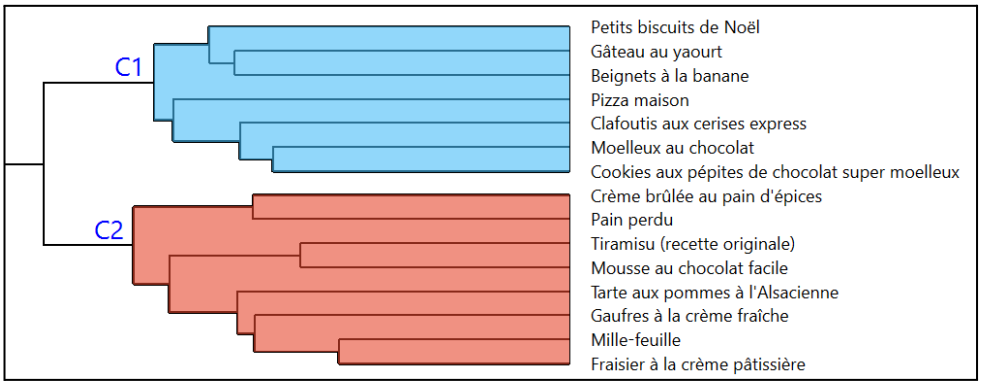


Figure 9 - Capture d'écran du document orange - Hierarchical Clustering : sous-clusters du cluster sucré (distance cosinus).

Le regroupement global du sucré s'explique par la répétition de mots très caractéristiques : sucre, œufs, farine, chocolat, jaune, mélanger, fouetter, etc. Ces termes sont rares dans les recettes salées, ce qui crée une séparation nette. Deux sous-clusters sont également visibles :

★ Le premier sous-cluster (C1) a l'air de regrouper les recettes dont la préparation se résume surtout à mélanger les ingrédients puis à cuire, souvent au four.

La pizza maison apparaît ici probablement parce que la première partie de la recette concerne la pâte : *farine, levure, eau*, un vocabulaire assez proche de celui des gâteaux simples présents dans ce sous-cluster.

Le beignet est également inclus, alors que sa cuisson se fait dans l'huile ; mais comme la recette est courte et repose sur les mêmes ingrédients de base (œufs, farine, sucre), il est logique qu'Orange le rapproche de ce groupe.

★ Le deuxième sous-cluster (C2) regroupe des recettes qui demandent plus d'étapes ou une préparation plus technique.

Par exemple, la tarte aux pommes à l'alsacienne nécessite de couper les pommes, de disposer les morceaux d'une certaine manière, de préparer ou manipuler une pâte brisée... Ce sont des recettes globalement plus longues, avec un vocabulaire plus varié et des instructions plus détaillées.

- **Cluster 2 (C2) : recettes salées**

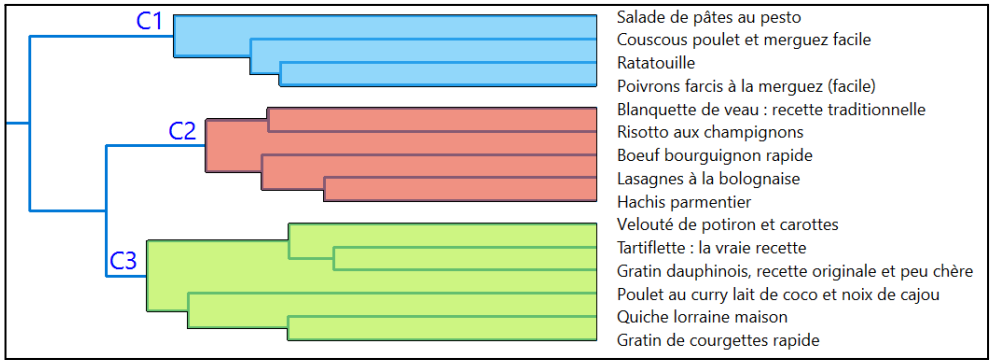


Figure 10 - Capture d'écran du document orange - Hierarchical Clustering : sous-clusters du cluster salé (distance cosinus).

Le vocabulaire typique des recettes salées (*sel*, *poivre*, *oignon*, *viande*, etc.) justifie naturellement leur regroupement. On observe trois sous-clusters, même si les frontières sont parfois moins faciles à interpréter :

★ Le premier sous-cluster (C1) contient les deux seules recettes contenant de la merguez. Les recettes ont aussi en commun un grand nombre d'occurrences du mot tomate, ce qui explique leur proximité.

★ Le deuxième sous-cluster (C2) semble regrouper les recettes qui consistent à mijoter, avec comme ingrédient majoritaire le champignon, oignon, viande.

★ Le troisième sous-cluster (C3) contient plusieurs recettes cuites au four, mais aussi une soupe et un poulet curry coco. Leur regroupement est moins évident. La proximité semble venir soit d'ingrédients communs, soit d'un style de préparation similaire.

B. Distance euclidienne normalisée

La distance euclidienne normalisée sépare bien les recettes sucrées et salées, mais elle produit beaucoup moins de sous-clusters exploitables.
Deux recettes se retrouvent nettement isolées :

- La pizza maison, car son vocabulaire est très particulier (préparation de pâte : *étalez*, *boule*, *collante*, etc.) et son texte est plus long que la moyenne.

- Le fraisier à la crème pâtissière, probablement à cause de la longueur importante de la recette et du nombre d'étapes.

La différence entre les deux distances s'explique par leur fonctionnement :

- La distance cosinus compare surtout la proportion des mots, ce qui met en avant les ressemblances de vocabulaire, même si les recettes sont longues ou courtes. C'est ce qui permet d'obtenir des sous-clusters propres.

- La distance euclidienne normalisée reste plus sensible à la quantité d'informations et à la longueur des textes. Elle repère bien les deux grands groupes (sucré/salé) mais elle est moins efficace à l'intérieur de ceux-ci.

C. Conclusion de l'analyse non supervisée

L'analyse des 30 recettes montre qu'Orange est capable de repérer des similarités textuelles assez cohérentes, surtout avec la distance cosinus. Les recettes se séparent naturellement en deux grands groupes, sucré et salé, grâce à un vocabulaire très spécifique à chaque catégorie. La distance cosinus permet aussi d'obtenir des sous-clusters plus propres et plus logiques, notamment pour les recettes sucrées où les modes de préparation et les ingrédients jouent un rôle important dans le regroupement.

À l'inverse, la distance euclidienne normalisée donne des résultats plus bruts : elle distingue bien sucré/salé, mais elle isole certaines recettes longues ou avec un vocabulaire particulier, comme la pizza maison ou le fraisier. Globalement, l'étude montre que la qualité du clustering dépend beaucoup de la distance choisie et que les textes courts et très typés sont plus faciles à regrouper.

2 - Apprentissage supervisé

2.1 - Jeu de données

Pour cette partie supervisée, on voulait travailler sur des données originales. On a donc choisi d'utiliser les animaux de compagnie de Cassandre comme sujets d'étude. Il s'agit d'un problème de classification d'images où l'objectif est d'identifier quel chat figure sur la photo.

Le jeu de données étiquetées est constitué de 65 photos de chats (les individus), réparties en 5 classes cibles correspondant aux noms des chats : Cotton, Fluffy, Paillette, Pysou et Susu. Chaque chat a une couleur différente.

Constitution du jeu de données : Les photos ont été prises en variant les angles et la luminosité. On a ensuite trié ces images manuellement dans des dossiers pour préparer le travail dans Orange :

1. **Les données d'entraînement (Train)** : On a créé un dossier contenant 5 sous-dossiers (un par nom de chat). On a placé 10 photos par chat, soit 50 photos au total pour l'apprentissage.
2. **Les données de test (Prédiction)** : On a mis de côté 3 photos par chat (15 photos au total) dans un dossier à part. Ces images ne sont pas "étiquetées" pour la machine : elles serviront à vérifier si le modèle arrive à reconnaître les chats sur des photos non classées.

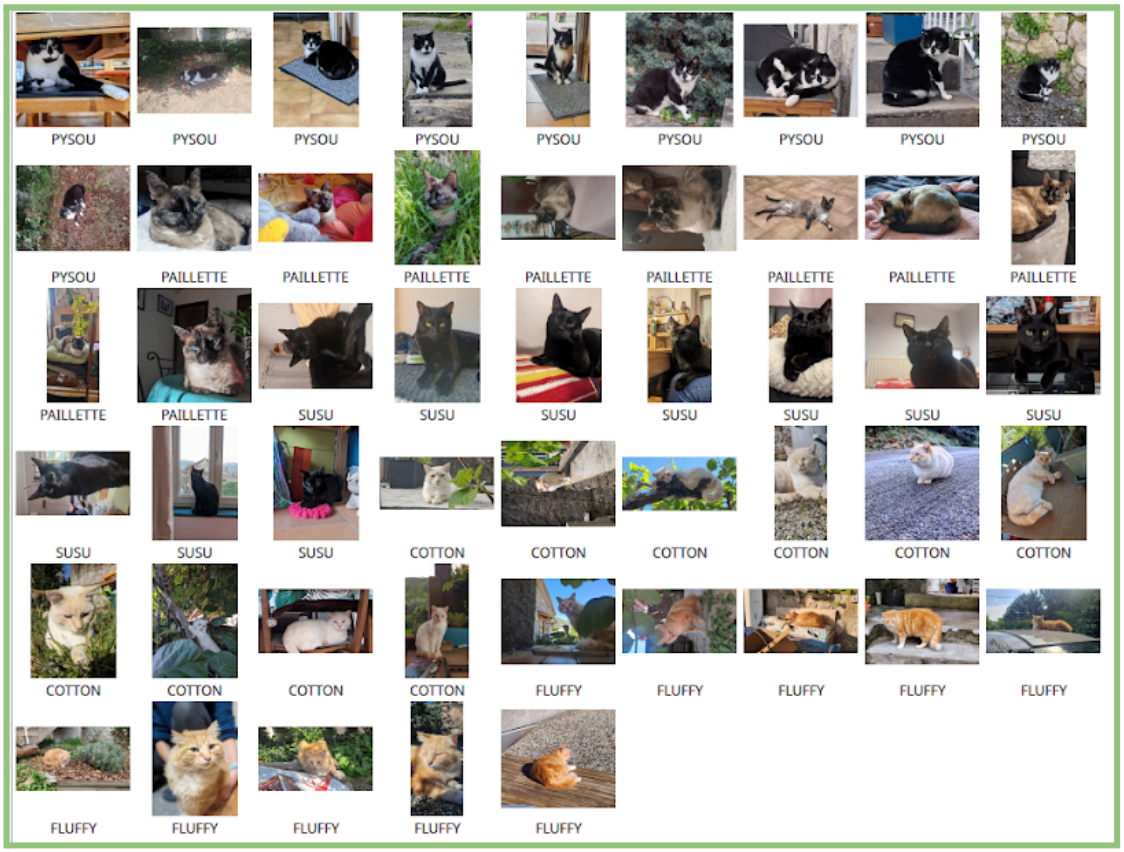


Figure 11 - Capture d'écran prise d'Image Viewer sur Orange : On y observe les 50 photos classées dans les 5 catégories.

2.2 - Chaîne de traitement

La chaîne de traitement mise en place dans Orange se divise en deux flux parallèles : l'apprentissage et la prédiction.

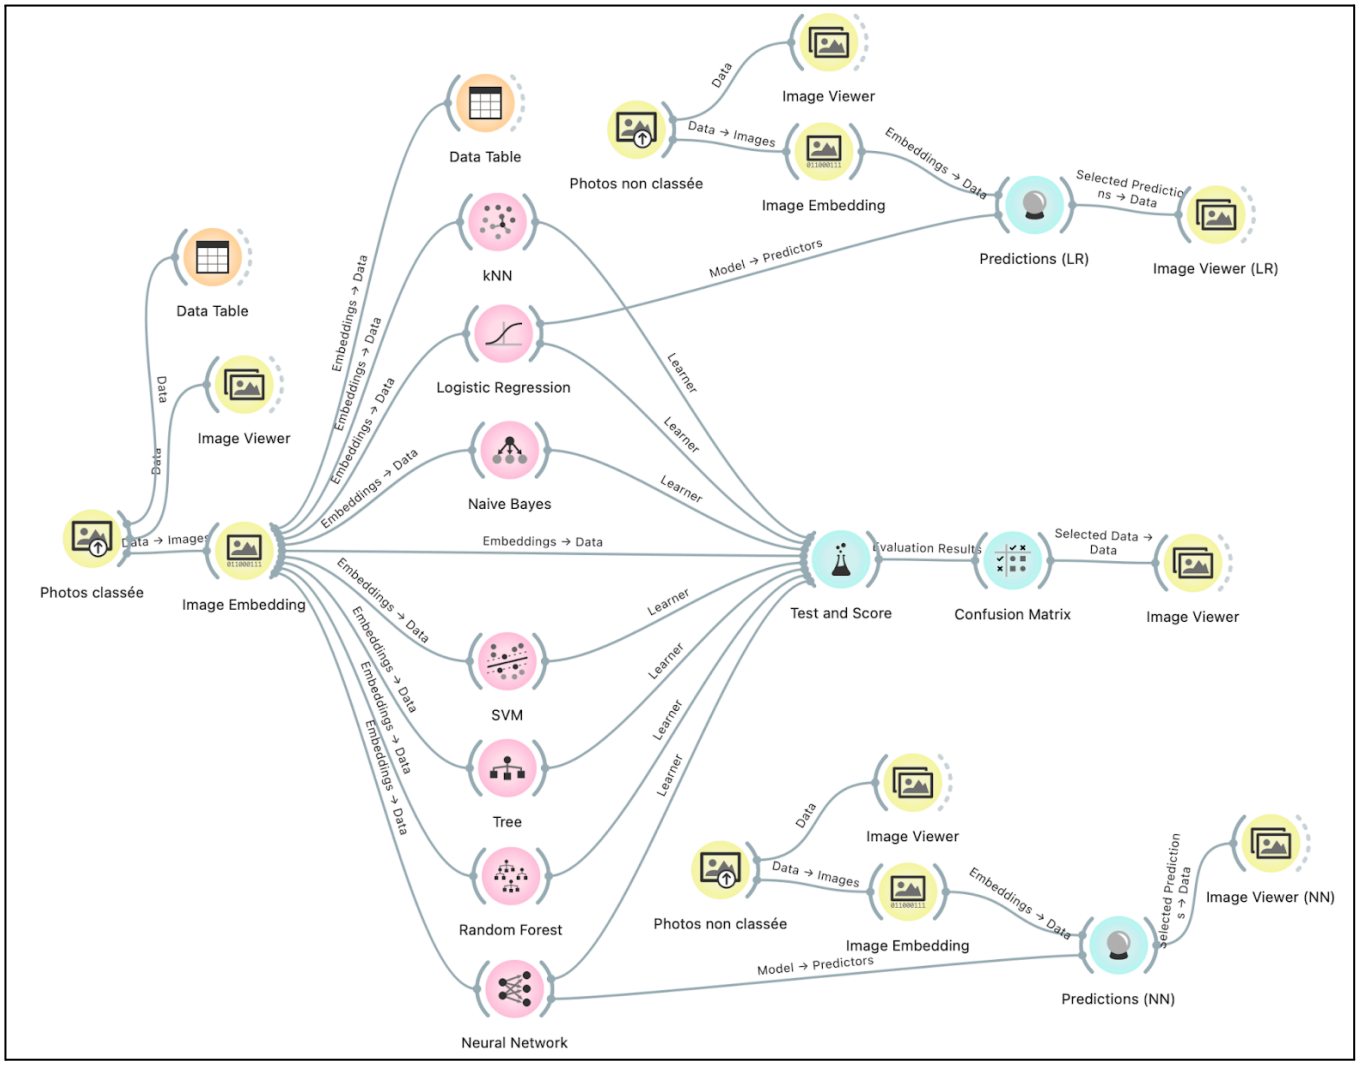


Figure 12 - Capture d'écran prise du Workflow d'Orange : On y observe la chaîne de traitement des données supervisées.

Pour l'apprentissage : On a d'abord utilisé le widget Import Images pour charger les 50 photos classées. Ces images passent ensuite par un widget Image Embedding (utilisant le modèle Inception v3). Cette étape est cruciale car elle transforme les images brutes en vecteurs numériques compréhensibles par l'ordinateur. Ces données sont ensuite envoyées vers un widget Test & Score auquel on a connecté plusieurs modèles pour les comparer (kNN, Random Forest, Neural Network, Logistic Regression, etc.).

Pour la prédiction : En parallèle, on a créé une seconde branche avec un nouveau Import Images contenant les 15 photos "non classées". Elles subissent le même traitement d'embedding avant d'être reliées au widget Predictions. Ce dernier utilise le meilleur modèle entraîné pour deviner l'identité du chat.

A. Démarche de prétraitement

1. Importation des Données : Deux widgets sont utilisés pour importer les images : l'un pour les 50 photos classées (jeu d'entraînement) et l'autre pour les 15 photos non classées (jeu de test/prédiction).

2. Extraction des caractéristiques (Image Embedding) : C'est l'étape cruciale de prétraitement pour l'analyse d'images. Les pixels bruts sont transformés en vecteurs numériques (ou embeddings) pour être interprétés par les algorithmes. On a utilisé le modèle Inception v3 dans le widget Image Embedding. Ce réseau neuronal pré-entraîné gère implicitement le nettoyage (redimensionnement et normalisation) des images et extrait les caractéristiques visuelles pertinentes (couleur, texture, forme) sur un vecteur de 2048 dimensions. On observe grâce aux widgets Data Table beaucoup plus d'information sur les images, Data Table nous informe de "2048 features" qui sont ajoutés grâce au widget Embedding.

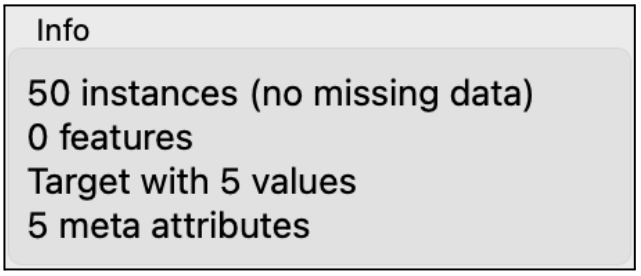


Figure 13 - Capture d'écran prise de data table connectée directement à l'importation de photos classe

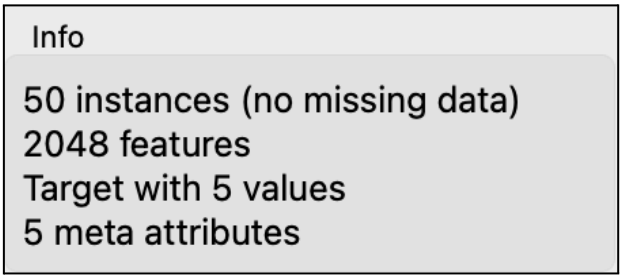


Figure 14 - Capture d'écran prise de data table connecte après l'Embedding des photos

B. Outils de classification et évaluation

★ **Modèles de classification** : On a testé sept algorithmes pour identifier le plus performant. Les modèles testés sont : kNN, Logistic Regression, Naive Bayes, SVM, Tree (Arbre de Décision), Random Forest, et Neural Network.

★ **Évaluation et Comparaison** :

- Le widget Test and Score a été configuré avec la Validation Croisée (Cross Validation) à 10 folds. Le Widget nous permet de voir les différentes valeurs de performances telle que l'Accuracy, le Recall, la Précision et le F1-Score de chaque Modèle de classification..
- Les résultats sont ensuite envoyés vers le widget Confusion Matrix pour analyser les erreurs spécifiques à chaque classe.

★ **Prédiction (Flux Parallèle)** : Les 15 photos non classées sont traitées via un second Image Embedding et envoyées au widget Predictions. Ce widget utilise le meilleur modèle entraîné (ici, la Regression Logistique) pour attribuer une étiquette de chat à chaque photo. Les résultats sont visualisés dans un Image Viewer.

2.3 - Interprétation

A. Description des résultats d'entraînement et comparaison des modèles

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Logistic Regression	0.996	0.960	0.960	0.960	0.960	0.950
kNN	0.980	0.860	0.857	0.902	0.860	0.836
Naive Bayes	0.984	0.880	0.878	0.879	0.880	0.851
SVM	0.954	0.860	0.859	0.868	0.860	0.827
Tree	0.763	0.620	0.617	0.623	0.620	0.527
Random Forest	0.917	0.740	0.736	0.750	0.740	0.680
Neural Network	0.997	0.940	0.939	0.940	0.940	0.925

Tableau 1 - Capture d'écran prise de Test and Score sur la moyenne de toutes les classes : On observe les résultats obtenus via le widget sur le jeu d'entraînement (validation croisée à 10 folds)

★ **Le Modèle le plus performant** : La Régression Logistique se révèle être le meilleur classificateur global, atteignant une Exactitude de 96% et un F1-Score de 0.960.

- Performance par Classe : Ce modèle atteint une performance parfaite (F1 = 1.000) pour l'identification de Paillette, Pysou et Susu.

★ **Le Modèle de Référence** : Le Neural Network démontre une performance presque équivalente avec 94% d'Exactitude, confirmant qu'il est également un excellent choix.

- Performance par Classe : Le Neural Network est le seul modèle, avec la Régression Logistique, à obtenir un score parfait pour Paillette et Susu. Fait notable, il parvient à une Exactitude parfaite (CA = 1.000) pour Paillette et Susu, et obtient également un F1-Score élevé pour Fluffy (0.900), égalant la Régression Logistique sur cette cible difficile.
- Point faible : L'analyse des cibles Cotton et Fluffy montre une légère baisse de performance (F1 = 0.900 pour les deux cibles).

★ **Le Modèle le Moins Performant** : L'Arbre de Décision (Tree) obtient la performance la plus faible avec seulement 62% d'Exactitude.

- Faiblesse Globale : Tree présente les résultats les plus faibles, avec un F1-Score global de 0.617. Il démontre une difficulté particulière à séparer les classes, comme le confirment ses faibles F1-Scores pour les cibles Cotton (0.667), Fluffy (0.545) et Pysou (0.444). Ce modèle est manifestement insuffisant pour généraliser correctement les différences subtiles entre les chats.

B. Interprétation des échecs et des limites

D’après le widget Confusion Matrice sur les photos classées par Régression Logistique, on se fait une idée visuelle sur les points fort et faible de ce modèle face aux photos.

- ★ Classes Parfaitement Identifiées : Les chats Paillette, Pysou et Susu n'ont généré aucune fausse classification sur les 10 exemples de la validation croisée.
- ★ La Confusion Majeure (Limite du Système) : Les seules erreurs se concentrent sur la paire Cotton et Fluffy :
    - Une image de Cotton a été incorrectement prédite comme Fluffy.
    - Une image de Fluffy a été incorrectement prédite comme Cotton.



Figure 15 - Capture d’écran prise d'Image Viewer après confusion Matrix de régression Logistique: On observe que Cotton (Le chat blanc) est classe comme Fuffy (Le chat roux) et vise et versa.

On peut former 2 hypothèses face à cette erreur :

- ★ **Hypothèse de Similarité Visuelle :** Cotton et Fluffy partagent des caractéristiques physiques (couleur de pelage ayant tous deux du blanc et roux, morphologie, etc.) qui sont quelque peu proches. Le modèle peut peiner à distinguer les variations fines qui les séparent.
- ★ **Hypothèse d'Échantillonnage :** Avec seulement 10 images par chat, les photos de Cotton et Fluffy ont été prises dans des conditions similaires, car ce sont deux chats qui vivent dans le même environnement ensemble – par opposition aux autres chats dont les images sont plus distinctes (chats d’extérieur/ chats d'intérieur) l'algorithme a pu se concentrer sur des caractéristiques contextuelles non discriminantes, augmentant la confusion.

On note que régression logistique n'est pas le seul modèle à faire cette erreur entre Fluffy et Cotton sur les mêmes images, car Neural Network la fait aussi.

C. Analyse de la prédiction sur le jeu de test (15 Photos non classées) :

Pour valider la capacité de généralisation des modèles sur des données réellement jamais vues, on a utilisé un jeu de test indépendant de 15 photographies (3 par chat). L'analyse a été menée sur les deux meilleurs modèles : la Régression Logistique et le Neural Network.

Performance des modèles sur les photos non classées

- ➔ Régression Logistique (RL) : La Régression Logistique, bien que meilleure sur l'évaluation par validation croisée (CA = 96% vs 94% pour le NN), a commis une erreur sur le jeu de test.
- ➔ Neural Network (NN) : Le modèle de Neural Network a classé les 15 photos non classées avec une Exactitude de 100%. Il a réussi à identifier correctement chaque chat du jeu de test.

Interprétation de l'erreur de la régression logistique

L'erreur identifiée est la suivante : une photo du chat Susu a été classée incorrectement comme Paillette par le modèle de Régression Logistique.

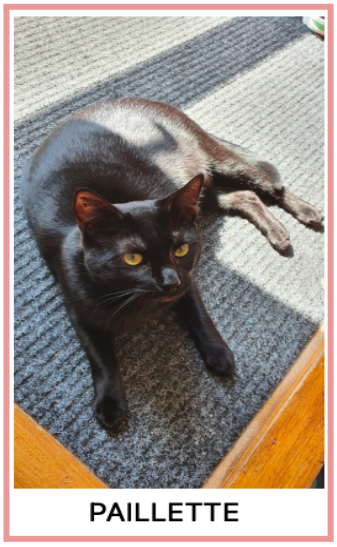


Figure 16 - Capture d'écran prise d'Image Viewer après prédictions de Régression Logistique: On observe que Susu (chat noir) est classe comme Paillette (une chatte de pelage blanc-gris et brun).

Caractère surprenant de l'erreur : Cette confusion (Susu ⇒ Paillette) est surprenante, car elle n'apparaissait pas dans la Matrice de Confusion de la validation croisée. L'erreur principale lors de l'entraînement était strictement limitée à la paire Cotton/Fluffy.

Explication de la Limite de Généralisation : Ce phénomène met en lumière la limite de généralisation du modèle. Bien que la Régression Logistique ait trouvé une frontière de décision optimale pour l'ensemble d'entraînement, cette unique photo de Susu possède des caractéristiques (éclairage, angle, position) suffisamment différentes de l'ensemble d'entraînement pour la faire chuter du mauvais côté de la frontière de décision, dans l'espace de Paillette.

D. Conclusion de l'Analyse Supervisée

L'étude comparative révèle une performance globale exceptionnelle de la chaîne de traitement avec les deux meilleurs modèles de classification (Régression Logistique et Neural Network).

Toutefois, l'analyse détaillée a permis :

- ★ D’identifier la limite principale liée à la similarité physique et environnementale entre Cotton et Fluffy (via la validation croisée).
- ★ D’identifier un cas d'échec imprévu sur le jeu de test pour la Régression Logistique (Susu confondu avec Paillette), illustrant que les performances de la validation croisée peuvent surestimer légèrement la performance réelle sur des données réellement inédites.

Le Neural Network se révèle être le plus robuste sur ce jeu de test, en réussissant à identifier les 15 photos sans erreur, ce qui en fait le meilleur modèle à retenir pour une application pratique.

Sources

marmiton/recette_quiche-lorraine
marmiton/recette_ratatouille
marmiton/recette_blanquette-de-veau-facile
marmiton/recette_boeuf-bourguignon-rapide
marmiton/recette_lasagnes-a-la-bolognaise
marmiton/recette_couscous-poulet-et-merguez-facile
marmiton/recette_hachis-parmentier
marmiton/recette_pizza-maison
marmiton/recette_la-vraie-tartiflette
marmiton/recette_poivrons-farcis-a-la-merguez-facile
marmiton/recette_veloute-de-potiron-et-carottes
marmiton/recette_salade-de-pates-au-pesto
marmiton/recette_poulet-au-curry-lait-de-coco-et-noix-de-cajou
marmiton/recette_gratin-dauphinois-recette-originale
marmiton/recette_gratin-de-courgettes-rapide
marmiton/recette_risotto-aux-champignons-recette-italienne-du-risotto-alla-fungaiola

marmiton/recette_gateau-au-yaourt
marmiton/recette_moelleux-au-chocolat
marmiton/recette_tarte-aux-pommes-a-l-alsacienne
marmiton/recette_clafoutis-aux-cerises-express
marmiton/recette_tiramisu-recette-originale
marmiton/recette_creme-brulee-au-pain-d-epice
marmiton/recette_cookies-aux-pepites-de-chocolat-super-moelleux
marmiton/recette_gaufres-a-la-creme-fraiche
marmiton/recette_mille-feuilles
marmiton/recette_mousse-au-chocolat-facile
marmiton/recette_petits-biscuits-de-noel
marmiton/recette_beignets-a-la-banane
marmiton/recette_pain-perdu
marmiton/recette_fraisier-a-la-creme-patissiere